

Proyecto Final

Nombre de la Materia: Minería de datos

Nombre del alumno: Israel Morante Luna

Matricula: 202245166

ÍNDICE

Extraer, Transformar y Analizar.....	3
Extrayendo datos:.....	3
Tipos de datos:.....	3
Transformando y Analizando datos:.....	8
Limpieza de Datos.....	11
Redefiniendo Nombres.....	11
Reduciendo Categorías.....	13
Valores Faltantes.....	16
Análisis Exploratorio de datos:.....	20
Histogramas:.....	20
Diagramas de Barras y de Pastel:.....	25
Boxplots:.....	28
Matriz de correlación y gráficos de dispersión:.....	30
Planteamiento del Problema.....	32
Propuesta de Solución.....	32
Distribución de la variable objetivo.....	32
Tratamiento de valores atípicos.....	33
Entrenamiento del modelo.....	35
Comprobación de supuestos de regresión lineal.....	38
Los errores deben seguir una distribución normal.....	38
No debe haber heterocedasticidad.....	40
No debe haber multicolinealidad.....	42
No debe haber correlación serial automática.....	42
Medición del Modelo.....	43
Posibles mejoras al modelo.....	44
Conclusiones.....	44

Extraer, Transformar y Analizar

Extrayendo datos:

Para la extracción de datos en este caso, el dataset se obtendrá de un archivo csv, por medio de la función `read.csv` de `r`, `na.strings`, el valor de este apartado se menciona y se modifica debido a que los valores vacíos pueden prestarse a no ser reconocido como nulos, para ello los reemplazamos al cargar los datos por un valor `NA`.

```
> cardata <- read.csv("car details v4.csv",na.strings = c("", "NA"))
> dim(cardata)
[1] 2059 20
```

Se realiza la extracción de los datos, como podemos ver nuestro dataset contiene 2059 observaciones con 20 variables distintas de cada compra realizada.

Tipos de datos:

Con nuestros datos cargados, veremos de qué naturaleza son cada una de las variables contenidas en el dataset, para obtener una idea general y más clara del contenido del dataset. Para realizar esto haremos uso de las siguientes funciones disponible en Rstudio, tales como `"str()"` - para obtener un resumen de los datos, `"summary()"` - la cual nos proporciona una descripción estadística de cada variable disponible y por último la función `"head()"` - para imprimir las 10 primeras observaciones del dataframe.

```
> str(cardata)
```

```
'data.frame':      2059 obs. of  20 variables:
 $ Make           : chr  "Honda" "Maruti Suzuki" "Hyundai" "Toyota" ...
 $ Model          : chr  "Amaze 1.2 VX i-VTEC" "Swift DZire VDI" "i10
Magna 1.2 Kappa2" "Glanza G" ...
 $ Price          : int   505000 450000 220000 799000 1950000 675000
1898999 2650000 1390000 575000 ...
 $ Year           : int   2017 2014 2011 2019 2018 2017 2015 2017 2017 2015
...
 $ Kilometer      : int   87150 75000 67000 37500 69000 73315 47000 75000
56000 85000 ...
 $ Fuel.Type      : chr   "Petrol" "Diesel" "Petrol" "Petrol" ...
 $ Transmission   : chr   "Manual" "Manual" "Manual" "Manual" ...
 $ Location       : chr   "Pune" "Ludhiana" "Lucknow" "Mangalore" ...
 $ Color          : chr   "Grey" "White" "Maroon" "Red" ...
 $ Owner          : chr   "First" "Second" "First" "First" ...
```

```

$ Seller.Type      : chr  "Corporate" "Individual" "Individual"
"Individual" ...
$ Engine           : chr  "1198 cc" "1248 cc" "1197 cc" "1197 cc" ...
$ Max.Power        : chr  "87 bhp @ 6000 rpm" "74 bhp @ 4000 rpm" "79 bhp @
6000 rpm" "82 bhp @ 6000 rpm" ...
$ Max.Torque       : chr  "109 Nm @ 4500 rpm" "190 Nm @ 2000 rpm" "112.7619
Nm @ 4000 rpm" "113 Nm @ 4200 rpm" ...
$ Drivetrain       : chr  "FWD" "FWD" "FWD" "FWD" ...
$ Length           : num  3990 3995 3585 3995 4735 ...
$ Width            : num  1680 1695 1595 1745 1830 ...
$ Height           : num  1505 1555 1550 1510 1795 ...
$ Seating.Capacity : num  5 5 5 5 7 5 5 5 5 5 ...
$ Fuel.Tank.Capacity: num  35 42 35 37 55 43 NA 51 50 50 ...

```

```
> head(cardata, n=10)
```

Make	Model	Price	Year	Kilometer	Fuel.Type
1 Honda	Amaze 1.2 VX i-VTEC	505000	2017	87150	
Petrol Manual Pune Grey					
2 Maruti Suzuki	Swift DZire VDI	450000	2014	75000	
Diesel Manual Ludhiana White					
3 Hyundai	i10 Magna 1.2 Kappa2	220000	2011	67000	
Petrol Manual Lucknow Maroon					
4 Toyota	Glanza G	799000	2019	37500	
Petrol Manual Mangalore Red					
5 Toyota	Innova 2.4 VX 7 STR [2016-2020]	1950000	2018	69000	
Diesel Manual Mumbai Grey					
6 Maruti Suzuki	Ciaz ZXi	675000	2017	73315	
Petrol Manual Pune Grey					
7 Mercedes-Benz	CLA 200 Petrol Sport	1898999	2015	47000	
Petrol Automatic Mumbai White					
8 BMW	X1 xDrive20d M Sport	2650000	2017	75000	
Diesel Automatic Coimbatore White					
9 Skoda Octavia 1.8 TSI Style Plus AT [2017]		1390000	2017	56000	
Petrol Automatic Mumbai White					
10 Nissan	Terrano XL (D)	575000	2015	85000	
Diesel Manual Mumbai White					

Owner	Seller.Type	Engine	Max.Power	Max.Torque
1 First	Corporate	1198 cc	87 bhp @ 6000 rpm	109 Nm @ 4500 rpm
FWD	3990	1680	1505	5
2 Second	Individual	1248 cc	74 bhp @ 4000 rpm	190 Nm @ 2000 rpm
FWD	3995	1695	1555	5
3 First	Individual	1197 cc	79 bhp @ 6000 rpm	112.7619 Nm @ 4000 rpm
FWD	3585	1595	1550	5

4	First	Individual	1197 cc	82 bhp @ 6000 rpm	113 Nm @ 4200 rpm
FWD	3995	1745	1510	5	
5	First	Individual	2393 cc	148 bhp @ 3400 rpm	343 Nm @ 1400 rpm
RWD	4735	1830	1795	7	
6	First	Individual	1373 cc	91 bhp @ 6000 rpm	130 Nm @ 4000 rpm
FWD	4490	1730	1485	5	
7	Second	Individual	1991 cc	181 bhp @ 5500 rpm	300 Nm @ 1200 rpm
FWD	4630	1777	1432	5	
8	Second	Individual	1995 cc	188 bhp @ 4000 rpm	400 Nm @ 1750 rpm
AWD	4439	1821	1612	5	
9	First	Individual	1798 cc	177 bhp @ 5100 rpm	250 Nm @ 1250 rpm
FWD	4670	1814	1476	5	
10	First	Individual	1461 cc	84 bhp @ 3750 rpm	200 Nm @ 1900 rpm
FWD	4331	1822	1671	5	
	Fuel.Tank.Capacity				
1			35		
2			42		
3			35		
4			37		
5			55		
6			43		
7			NA		
8			51		
9			50		
10			50		

Ahora antes de seguir con la función “summary()”, describiremos los resultados arrojados por las funciones anteriores. Analizaremos cada variable observada.

- Make - chr esta variable es de tipo carácter, representa el fabricante del auto.
- Model - chr de tipo carácter, significando el modelo de dicho auto.
- Price - int es de tipo entero, haciendo referencia al precio de venta del auto.
- Year- int tipo entero, representando el año del auto.
- Kilometer - int tipo entero, describiendo el kilometraje recorrido por el auto.
- Fuel.Type - chr tipo carácter, mencionado el combustible de corresponde al auto.
- Transmission - chr tipo carácter, el tipo de caja de cambios del auto.
- Location - chr tipo carácter, el lugar de fabricación del auto.
- Color - chr tipo carácter, color del auto.
- Owner - cht tipo carácter, el número de dueños que ha tenido el auto.
- Seller.Type - chr tipo carácter, hace referencia al tipo de vendedor(como empresas o individuos).
- Engine - chr tipo carácter, describe el tipo de cilindrada del motor correspondiente al auto en centímetros cúbicos (cc).
- Max.Power - chr tipo carácter, describe la potencia máxima del motor según la frenada (bhp) dada a las revoluciones por minuto.
- Max.Torque - chr tipo carácter, se refiere al punto máximo de torque (Nm) según las revoluciones por minuto.
- Drivetrain - chr tipo carácter, describe el tipo de tracción de auto.

- Length - num tipo numérico, indica el largo del auto en mm(milímetros).
- Width - num tipo numérico, indica el ancho del auto mm(milímetros).
- Height - num tipo numérico, indica el alto del auto mm(milímetros).
- Seating.Capacity - num tipo numérico, hace referencia al número de asientos del auto.
- Fuel.Tank.Capacity - num tipo numérico, muestra la capacidad del tanque de gasolina.

Con esto realizado tenemos una mejor comprensión de las variables, pero para obtener un mejor conocimiento del comportamiento de las mismas usaremos la función “summary()” antes mencionada.

```
> summary(cardata)
```

Make	Model
Length:2059	Length:2059
Class :character	Class :character
Mode :character	Mode :character

Price	Year	Kilometer
Min. : 49000	Min. :1988	Min. : 0
1st Qu.: 484999	1st Qu.:2014	1st Qu.: 29000
Median : 825000	Median :2017	Median : 50000
Mean : 1702992	Mean :2016	Mean : 54225
3rd Qu.: 1925000	3rd Qu.:2019	3rd Qu.: 72000
Max. :35000000	Max. :2022	Max. :2000000

Fuel.Type	Transmission
Length:2059	Length:2059
Class :character	Class :character
Mode :character	Mode :character

Location	Color
Length:2059	Length:2059
Class :character	Class :character
Mode :character	Mode :character

Owner	Seller.Type
Length:2059	Length:2059

```
Class :character   Class :character
Mode  :character   Mode  :character
```

```
Engine             Max.Power
Length:2059        Length:2059
Class :character    Class :character
Mode  :character    Mode  :character
```

```
Max.Torque         Drivetrain         Length
Length:2059        Length:2059        Min.    :3099
Class :character    Class :character    1st Qu.:3985
Mode  :character    Mode  :character    Median :4370
                                     Mean   :4281
                                     3rd Qu.:4629
                                     Max.   :5569
                                     NA's   :64
```

```
Width              Height              Seating.Capacity
Min.    :1475      Min.    :1165      Min.    :2.000
1st Qu.:1695      1st Qu.:1485      1st Qu.:5.000
Median :1770      Median :1545      Median :5.000
Mean   :1768      Mean   :1592      Mean   :5.306
3rd Qu.:1832      3rd Qu.:1675      3rd Qu.:5.000
Max.   :2220      Max.   :1995      Max.   :8.000
NA's   :64        NA's   :64        NA's   :64
```

```
Fuel.Tank.Capacity
Min.    : 15.00
1st Qu.: 41.25
Median : 50.00
Mean   : 52.00
3rd Qu.: 60.00
Max.   :105.00
NA's   :113
```

Como se mencionó, esta función nos proporciona una descripción estadística de la cual obtenemos lo siguiente.

- De las variables de tipo carácter, no se puede obtener información relevante, lo cual indica que requieren algún tipo de transformación, como lo puede ser el convertirlas a variables de tipo factor.
- Con las variables Price y Kilometere, se observa una gran diferencia entre los valores min median y max, lo cual podría dar problemas a algunos modelos, debido a estos valores atípicos.
- De la variables Length, Width, Height, Seating.Capacity y Fuel.Tank.Capacity, vemos una mejor consistencia entre los valores Min, Median y Max, el detalle a resaltar de

estas variables son los valores faltantes, por lo cual habrá que tratar estas observaciones con alguna técnica de imputación adecuada.

Transformando y Analizando datos:

Lo siguiente, como se menciona en el título de esta sección, es dado lo extraído en la sección anterior, realizar un análisis más profundo de las variables problemáticas y transformarlas, antes de empezar crearemos una copia del dataset, para guardar el nuevo data frame transformado.

```
> cardataClean <- cardata
```

Empezaremos con las variables de tipo carácter, iremos de una en una, para corregir los problemas que presente cada variable.

Como primer paso tomaremos a la variable Make de tipo carácter, haremos uso de la función “str()” para examinar más de cerca a esta.

```
> str(cardataClean$Make)
```

```
chr [1:2059] "Honda" "Maruti Suzuki" "Hyundai" ...
```

Vemos que hay 2059 observaciones de modelo, pero muy posiblemente algunos de ellos se repetirán más de una vez, para confirmar esto y ver realmente cuánto modelo únicos existen en la variable Make usaremos la función “unique()”

```
> str(unique(cardataClean$Make))
```

```
chr [1:33] "Honda" "Maruti Suzuki" "Hyundai" ...
```

Con esto se confirma lo dicho con anterioridad, dado esto lo mejor para poder trabajar con esta variable, será transformarla a un tipo de variable factor con la función “factor()”.

```
> cardataClean$Make <- factor(cardataClean$Make)
```

Para comprobar que se hizo correctamente la transformación volvemos a hacer uso de la función “str()”.

```
> str(cardataClean$Make)
```

```
Factor w/ 33 levels "Audi","BMW","Chevrolet",...: 8 18 9 31 31 18 20 2 28 24 ...
```

Ahora con esto se puede ver que efectivamente solo existían 33 modelos únicos de autos en el dataset, con esto se obtiene una mejor información a través de la función estadística “summary()”.

```
> summary(cardataClean)
```

```
Make
Maruti Suzuki:440
Hyundai      :349
Mercedes-Benz:171
Honda        :158
Toyota       :132
Audi         :127
(Other)      :682
```

```
> summary(cardataClean$Make)
```

Audi		BMW	Chevrolet	Datsun	
	127		121	7	8
Ferrari			Fiat	Ford	Honda
	1		2	48	158
Hyundai			Isuzu	Jaguar	Jeep
	349		2	17	18
Kia		Lamborghini	Land Rover		Lexus
	23		1	33	6
Mahindra	Maruti Suzuki		Maserati	Mercedes-Benz	
	119		440	1	171
MG		MINI	Mitsubishi		Nissan
	17		11	4	16
Porsche		Renault	Rolls-Royce		Skoda
	15		43	3	40
Ssangyong		Tata	Toyota	Volkswagen	
	3		57	132	50
Volvo					
	16				

Con esta transformación realizada sobre la variable Make, obtenemos una información más clara y con mayor sentido. Haremos lo mismo para las demás variables de tipo chr (carácter) a continuación.

- De la variable Model.

```
> cardataClean$Model <- factor(cardataClean$Model)
```

- De la variable Fuel.Type.

```
> cardataClean$Fuel.Type <- factor(cardataClean$Fuel.Type)
```

- De la variable Transmission.

```
> cardataClean$Transmission <- factor(cardataClean$Transmission)
```

- De la variable Location.

```
> cardataClean$Location <- factor(cardataClean$Location)
```

- De la variable Color.

```
> cardataClean$Color <- factor(cardataClean$Color)
```

- De la variable Owner.

```
> cardataClean$Owner <- factor(cardataClean$Owner)
```

- De la variable Seller.Type

```
> cardataClean$Seller.Type <- factor(cardataClean$Seller.Type)
```

- De la variable Engine.

```
> cardataClean$Engine <- factor(cardataClean$Engine)
```

- De la variable Max.Power.

```
> cardataClean$Max.Power <- factor(cardataClean$Max.Power)
```

- De la variable Max.Torque.

```
> cardataClean$Max.Torque <- factor(cardataClean$Max.Torque)
```

- De la variable Drivetrain.

```
> cardataClean$Drivetrain <- factor(cardataClean$Drivetrain)
```

Limpieza de Datos.

Primero redefinimos los nombres de las variables, a un encabezado más significativo y en español, con ayuda de la librería dplyr y comprobaremos los cambios con la función “str()”..

Redefiniendo Nombres.

```
> cardataClean <- cardataClean %>%
+   rename("Fabricante"= "Make",
+         "Modelo"= "Model",
+         "Precio.de.Venta"= "Price",
+         "Año.de.Fabricacion"= "Year",
+         "Kilometraje.del.auto"= "Kilometer",
+         "Tipo.de.Gasolina"= "Fuel.Type",
+         "Tipo.de.Transmision"= "Transmission",
+         "Lugar.de.Fabricacion"= "Location",
+         "Color.del.auto"= "Color",
+         "Cantidad.de.dueños"= "Owner",
+         "Tipo.de.Vendedor"= "Seller.Type",
+         "Cilindrada.del.Motor"= "Engine",
+         "Caballos.de.Fuerza"= "Max.Power",
+         "Torque"= "Max.Torque",
+         "Tipo.de.traccion"= "Drivetrain",
+         "Largo.del.auto"= "Length",
+         "Ancho.del.auto"= "Width",
+         "Alto.delauto"= "Height",
+         "Numero.de.asientos"= "Seating.Capacity",
+         "Capacidad.de.Gasolina"= "Fuel.Tank.Capacity"
+   )
> str(cardataClean)
```

```
'data.frame':      2059 obs. of  20 variables:
 $ Fabricante      : Factor w/ 33 levels "Audi","BMW","Chevrolet",...: 8
18 9 31 31 18 20 2 28 24 ...
 $ Modelo          : Factor w/ 1050 levels "2 Series Gran Coupe 220d M
Sport [2020-2021]",...: 106 831 551 480 578 211 247 980 654 858 ...
 $ Precio.de.Venta : int  505000 450000 220000 799000 1950000 675000
1898999 2650000 1390000 575000 ...
```

```

$ Año.de.Fabricacion : int 2017 2014 2011 2019 2018 2017 2015 2017 2017
2015 ...
$ Kilometraje.del.auto : int 87150 75000 67000 37500 69000 73315 47000
75000 56000 85000 ...
$ Tipo.de.Gasolina : Factor w/ 9 levels "CNG","CNG + CNG",...: 7 3 7 7 3
7 7 3 7 3 ...
$ Tipo.de.Transmision : Factor w/ 2 levels "Automatic","Manual": 2 2 2 2 2
2 1 1 1 2 ...
$ Lugar.de.Fabricacion : Factor w/ 77 levels "Agra","Ahmedabad",...: 57 41 40
42 46 57 46 13 46 46 ...
$ Color.del.auto : Factor w/ 17 levels "Beige","Black",...: 8 16 9 14 8
8 16 16 16 16 ...
$ Cantidad.de.dueños : Factor w/ 6 levels "4 or More","First",...: 2 4 2 2
2 2 4 4 2 2 ...
$ Tipo.de.Vendedor : Factor w/ 3 levels "Commercial Registration",...: 2
3 3 3 3 3 3 3 3 3 ...
$ Cilindrada.del.Motor : Factor w/ 108 levels "1047 cc","1061 cc",...: 8 10 7
7 61 17 47 48 38 22 ...
$ Caballos.de.Fuerza : Factor w/ 335 levels "100 bhp @ 3600 rpm",...: 313
290 302 306 79 325 133 145 125 308 ...
$ Torque : Factor w/ 290 levels "101 Nm @ 3000 rpm",...: 6 78
12 16 168 32 145 200 122 91 ...
$ Tipo.de.traccion : Factor w/ 3 levels "AWD","FWD","RWD": 2 2 2 2 3 2 2
1 2 2 ...
$ Largo.del.auto : num 3990 3995 3585 3995 4735 ...
$ Ancho.del.auto : num 1680 1695 1595 1745 1830 ...
$ Alto.delauto : num 1505 1555 1550 1510 1795 ...
$ Numero.de.asientos : num 5 5 5 5 7 5 5 5 5 5 ...
$ Capacidad.de.Gasolina: num 35 42 35 37 55 43 NA 51 50 50 ...

```

Reduciendo Categorías.

Con el renombramiento hecho y las variables en tipo facto, podemos ver que tenemos demasiado nivel para algunas variables, así que para tener una mejor simplicidad y claridad en nuestros datos reduciremos esos niveles a continuación.

De la variable Fabricante:

Primero obtendremos los valores únicos de esta variable con la función “unique()”.

```
> unique(cardataClean$Fabricante)
```

```

[1] "Honda"           "Maruti Suzuki" "Hyundai"
[4] "Toyota"          "Mercedes-Benz" "BMW"
[7] "Skoda"           "Nissan"         "Renault"
[10] "Tata"            "Volkswagen"    "Ford"
[13] "Audi"            "Mahindra"      "MG"

```

[16] "Jeep"	"Porsche"	"Kia"
[19] "Land Rover"	"Volvo"	"Maserati"
[22] "Jaguar"	"Isuzu"	"Fiat"
[25] "MINI"	"Ferrari"	"Mitsubishi"
[28] "Datsun"	"Lamborghini"	"Chevrolet"
[31] "Ssangyong"	"Rolls-Royce"	"Lexus"

Ahora para poder reducir estas diferentes categorías, agrupamos a los fabricantes según el continente de su sede central. Por ejemplo, Kia, Hyundai y Maruti Suzuki entrarían en el continente Asiático.

```
> cardataClean$Fabricante[cardataClean$Fabricante == 'Honda'] <- 'Asiatico'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Maruti Suzuki'] <-
'Asiatico'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Hyundai'] <-
'Asiatico'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Toyota'] <- 'Asiatico'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Nissan'] <- 'Asiatico'
> cardataClean$Fabricante[cardataClean$Fabricante == 'MG'] <- 'Asiatico'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Kia'] <- 'Asiatico'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Isuzu'] <- 'Asiatico'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Mitsubishi'] <-
'Asiatico'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Ssangyong'] <-
'Asiatico'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Lexus'] <- 'Asiatico'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Datsun'] <- 'Asiatico'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Mercedes-Benz'] <-
'Europeos'
> cardataClean$Fabricante[cardataClean$Fabricante == 'BMW'] <- 'Europeos'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Skoda'] <- 'Europeos'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Renault'] <-
'Europeos'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Volkswagen'] <-
'Europeos'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Audi'] <- 'Europeos'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Porsche'] <-
'Europeos'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Volvo'] <- 'Europeos'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Maserati'] <-
'Europeos'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Jaguar'] <- 'Europeos'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Fiat'] <- 'Europeos'
> cardataClean$Fabricante[cardataClean$Fabricante == 'MINI'] <- 'Europeos'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Ferrari'] <-
'Europeos'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Lamborghini'] <-
'Europeos'
```

```

> cardataClean$Fabricante[cardataClean$Fabricante == 'Rolls-Royce'] <-
'Europeos'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Ford'] <- 'Americanos'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Jeep'] <- 'Americanos'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Land Rover'] <-
'Americanos'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Chevrolet'] <-
'Americanos'
> #Reemplazando a los fabricantes Africanos
> cardataClean$Fabricante[cardataClean$Fabricante == 'Tata'] <- 'Africanos'
> cardataClean$Fabricante[cardataClean$Fabricante == 'Mahindra'] <-
'Africanos'
> cardataClean$Fabricante <- factor(cardataClean$Fabricante)
> str(cardataClean$Fabricante)

```

```

Factor w/ 4 levels "Africanos","Americanos",...: 3 3 3 3 3 3 4 4 4 3 ...

```

Como se observa teníamos una variable factor de 33 niveles, pero la hemos reducido agrupando a una variable de 4 niveles solamente lo cual es más legible y fácil de recordar.

De la variable Largo.del.auto

Si todavía no empezamos a trabajar con las variables de tipo int, pero es necesario hacer algo al respecto con sus valores nulos de esta variable, ya que con esta información, vamos a corregir el problema de los niveles de la variable Modelo. Así que para poder arreglar este problema de valores nulos, lo haremos reemplazando esos valores por la media de la siguiente manera.

```

>cardataClean$Largo.del.auto[is.na(cardataClean$Largo.del.auto)]<-mean(cardat
aClean$Largo.del.auto,na.rm=TRUE)

```

Con esto hecho ya podemos trabajar con esta variable sin ningún problema.

De la variable Modelo.

Para trabajar esta variable es más complicado si seguimos la misma estrategia que usamos anteriormente, para esto nos ayudaremos de otra variable más, la cual es el largo del auto, con esto podremos clasificar en diversos segmentos existentes en el mercado. La estrategia a seguir es la siguiente, primero definiremos los parámetros frontera, como lo son el valor máximo y mínimo, con funciones de r, para después empezar a agrupar según su tamaño.

```

> max(cardataClean$Largo.del.auto, na.rm = T)

```

```
[1] 5569
```

```
> min(cardataClean$Largo.del.auto, na.rm = T)
```

```
[1] 3099
```

Con estas medidas en mm, tenemos que el auto más largo es de 5.5 metros y el más chico es de 3 metros. Dado esto podemos decir que tenemos que tendremos 6 niveles, según la clasificación de los autos por segmentos de la A a la F.

Para hacer esta agrupación hacemos uso del siguiente código.

```
> min(cardataClean$Largo.del.auto, na.rm = T)
[1] 3099
> #cardataClean <- cardataClean %>% mutate(Fabricante = ifelse(Largo.del.auto
>= 50, "Aprobado", "Reprobado"))
> cardataClean$Modelo <- cut(cardataClean$Largo.del.auto, breaks = c(3099,
3700, 4000, 4500, 4700, 5000, 5570),
+                               include.lowest = T,
+                               labels = c("Segmento A", "Segmento B", "Segmento
C", "Segmento D", "Segmento E", "Segmento F"))
> summary(cardataClean$Modelo)
```

Segmento A	Segmento B	Segmento C	Segmento D	Segmento E
260	549	623	254	295
Segmento F				
78				

Así es como pasamos de tener 1050 niveles a solo 6 niveles agrupados.

Valores Faltantes.

De la variable Cilindrada de Motor

En esta variable podemos observar que su naturaleza es numérica, solo que tiene cc, que indica la medida que se utiliza, para poder pasar esta variable a tipo entero, hay que eliminar esa cadena y el espacio existente de la siguiente forma.

```
> cardataClean$`Cilindrada.del.Motor(cc)` <- as.numeric(gsub("\\D", "",
cardataClean$`Cilindrada.del.Motor(cc)`))
```

```
> summary(cardataClean$`Cilindrada.del.Motor(cc)`)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.	NA's
624	1197	1498	1693	1995	6592	80

Listo, con esto bien tenemos la variable en tipo entero, pero sigue teniendo problemas con valores faltantes, así que esos valores los reemplazamos por la media de la variable.

```
> cardataClean$`Cilindrada.del.Motor(cc)`[is.na(cardataClean$`Cilindrada.del.Motor(cc)`)] <- mean(cardataClean$`Cilindrada.del.Motor(cc)` , na.rm=TRUE)
> summary(cardataClean$`Cilindrada.del.Motor(cc)`)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
624	1198	1498	1693	1995	6592

Haremos esto mismo con las siguientes variables.

De la variable [Numero.de.Asientos](#).

```
> cardataClean$Numero.de.asientos[is.na(cardataClean$Numero.de.asientos)] <- mean(cardataClean$Numero.de.asientos, na.rm=TRUE)
> summary(cardataClean$Numero.de.asientos)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
2.000	5.000	5.000	5.306	5.000	8.000

De la variable [Capacidad.de.Gasolina](#).

```
> cardataClean$Capacidad.de.Gasolina[is.na(cardataClean$Capacidad.de.Gasolina)] <- mean(cardataClean$Capacidad.de.Gasolina, na.rm=TRUE)
> summary(cardataClean$Capacidad.de.Gasolina)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
15	42	50	52	60	105

De la variable Ancho.del.Auto.

```
>cardataClean$Ancho.del.auto[is.na(cardataClean$Ancho.del.auto)]<-mean(cardataClean$Ancho.del.auto,na.rm=TRUE)
> summary(cardataClean$Ancho.del.auto)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
1475	1695	1768	1768	1831	2220

De la variable Alto.del.Auto.

```
>cardataClean$Alto.delauto[is.na(cardataClean$Alto.delauto)]<-mean(cardataClean$Alto.delauto,na.rm=TRUE)
> summary(cardataClean$Alto.delauto)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
1165	1485	1550	1592	1672	1995

Por último para las variables categóricas Potencia.Máxima.del.Motor, Punto.Máximo.del.Torque, [Tipo.de.tracción](#), contienen valores nulos, al ser categóricas, reemplazamos los valores faltantes por la moda de cada variable factor excepto la variable Punto.Máximo.del.Torque a esta sus datos nulos los trataremos como una categoría más, en este caso con el nombre de desconocido.

```
> cardataClean$Potencia.Maxima.del.Motor <- as.character(cardataClean$Potencia.Maxima.del.Motor)
> cardataClean$Potencia.Maxima.del.Motor[is.na(cardataClean$Potencia.Maxima.del.Motor)] <- mlv(cardataClean$Potencia.Maxima.del.Motor)
> cardataClean$Potencia.Maxima.del.Motor <- factor(cardataClean$Potencia.Maxima.del.Motor)
cardataClean$Punto.Maximo.del.Torque <- as.character(cardataClean$Punto.Maximo.del.Torque)
> #mlv(cardataClean$Punto.Maximo.del.Torque)
> cardataClean$Punto.Maximo.del.Torque[is.na(cardataClean$Punto.Maximo.del.Torque)] <- 'desconocido'
> cardataClean$Punto.Maximo.del.Torque <- factor(cardataClean$Punto.Maximo.del.Torque)
```

```
> cardataClean$Tipo.de.traccion <-
as.character(cardataClean$Tipo.de.traccion)
> cardataClean$Tipo.de.traccion[is.na(cardataClean$Tipo.de.traccion)] <-
mlv(cardataClean$Tipo.de.traccion)
> cardataClean$Tipo.de.traccion <- factor(cardataClean$Tipo.de.traccion)
```

Con todo lo realizado anteriormente obtenemos el siguiente dataframe limpio.

```
> summary(cardataClean)
```

Fabricante	Modelo	Precio.de.Venta	Año.de.Fabricacion
Africanos : 176	Segmento A:260	Min. : 49000	Min. :1988
Americanos: 106	Segmento B:549	1st Qu.: 484999	1st Qu.:2014
Asiatico :1158	Segmento C:623	Median : 825000	Median :2017
Europeos : 619	Segmento D:254	Mean : 1702992	Mean :2016
	Segmento E:295	3rd Qu.: 1925000	3rd Qu.:2019
	Segmento F: 78	Max. :35000000	Max. :2022

Kilometraje.del.auto	Tipo.de.Gasolina	Tipo.de.Transmision
Lugar.de.Fabricacion		
Min. : 0	Diesel :1049	Automatic: 926
1st Qu.: 29000	Petrol : 942	Manual :1133
Median : 50000	CNG : 50	
Mean : 54225	Electric: 7	
3rd Qu.: 72000	LPG : 5	
Max. :2000000	Hybrid : 3	
	(Other) : 3	

Color.del.auto	Cantidad.de.dueños	Tipo.de.Vendedor
White :802	4 or More : 1	Commercial Registration: 5
Silver :285	First :1619	Corporate : 57
Grey :220	Fourth : 3	Individual :1997
Blue :190	Second : 373	
Black :163	Third : 42	
Red :154	UnRegistered Car: 21	
(Other):245		

Cilindrada.del.Motor(cc)	Potencia.Maxima.del.Motor
Min. : 624	89 bhp @ 4000 rpm : 90
1st Qu.:1198	82 bhp @ 6000 rpm : 62
Median :1498	126 bhp @ 4000 rpm: 55
Mean :1693	83 bhp @ 6000 rpm : 55
3rd Qu.:1995	74 bhp @ 4000 rpm : 50
Max. :6592	117 bhp @ 6600 rpm: 39
	(Other) :1708

Punto.Maximo.del.Torque	Tipo.de.traccion	Largo.del.auto	Ancho.del.auto
200 Nm @ 1750 rpm: 90	AWD: 272	Min. :3099	Min. :1475
desconocido : 80	FWD:1466	1st Qu.:3986	1st Qu.:1695
115 Nm @ 4000 rpm: 78	RWD: 321	Median :4315	Median :1768

114 Nm @ 4000 rpm:	66	Mean	:4281	Mean	:1768
90 Nm @ 3500 rpm :	64	3rd Qu.:	4620	3rd Qu.:	1831
400 Nm @ 1750 rpm:	63	Max.	:5569	Max.	:2220
(Other)	:1618				
Alto.delauto	Numero.de.asientos	Capacidad.de.Gasolina			
Min.	:1165	Min.	:2.000	Min.	: 15
1st Qu.:	1485	1st Qu.:	5.000	1st Qu.:	42
Median	:1550	Median	:5.000	Median	: 50
Mean	:1592	Mean	:5.306	Mean	: 52
3rd Qu.:	1672	3rd Qu.:	5.000	3rd Qu.:	60
Max.	:1995	Max.	:8.000	Max.	:105

Como se puede observar se obtienen datos limpios, esto significa que los datos nulos fueron tratados al igual que los problemas en algunas variables categóricas.


Análisis Exploratorio de datos:

En esta parte fundamental del proyecto analizaremos más a detalle las relaciones entre variables, su comportamiento, densidad, también posibles valores atípicos. Todo esto con las diversas funciones proporcionadas por las librerías del lenguaje R.


Histogramas:

Con ayuda de diversas librerías (pastecs,summarytools,DataExplorer, ggplot2,Alyto etc.) y funciones de R obtenemos lo siguiente.

```
> plot_histogram(cardataClean)
```



```
> plot_density(cardataClean)
```




```
> A <- ggplot(cardataClean, aes(x = Alto.del.aulo)) +
+   geom_histogram(aes(y = ..density..),
+     colour = 1, fill = "#8E6189") +
+   geom_density(lwd = 1, colour = 4,
+     fill = 4, alpha = 0.25)
> B <- ggplot(cardataClean, aes(x = Ancho.del.aulo)) +
+   geom_histogram(aes(y = ..density..),
+     colour = 1, fill = "#DA9556") +
+   geom_density(lwd = 1, colour = "#C71F3C",
+     fill = 4, alpha = 0.25)
> C <- ggplot(cardataClean, aes(x = Año.de.Fabricacion)) +
+   geom_histogram(aes(y = ..density..),
+     colour = 1, fill = "#BEC45C") +
+   geom_density(lwd = 1, colour = "#C71F3C",
+     fill = 4, alpha = 0.25)
> D <- ggplot(cardataClean, aes(x = Capacidad.de.Gasolina)) +
+   geom_histogram(aes(y = ..density..),
+     colour = 1, fill = "#CC1619") +
```

```

+ geom_density(lwd = 1, colour = "#C71F3C",
+             fill = 4, alpha = 0.25)
> E <- ggplot(cardataClean, aes(x = `Cilindrada.del.Motor(cc)`)) +
+   geom_histogram(aes(y = ..density..),
+                 colour = 1, fill = "#B44922") +
+   geom_density(lwd = 1, colour = "#C71F3C",
+               fill = 4, alpha = 0.25)
> f <- ggplot(cardataClean, aes(x = Kilometraje.del.auto)) +
+   geom_histogram(aes(y = ..density..),
+                 colour = 1, fill = "#C68FB5") +
+   geom_density(lwd = 1, colour = "#C71F3C",
+               fill = 4, alpha = 0.25)
> G <- ggplot(cardataClean, aes(x = Largo.del.auto)) +
+   geom_histogram(aes(y = ..density..),
+                 colour = 1, fill = "#E0CB48") +
+   geom_density(lwd = 1, colour = "#C71F3C",
+               fill = 4, alpha = 0.25)
> H <- ggplot(cardataClean, aes(x = Numero.de.asientos)) +
+   geom_histogram(aes(y = ..density..),
+                 colour = 1, fill = "#F1D5D0") +
+   geom_density(lwd = 1, colour = "#C71F3C",
+               fill = 4, alpha = 0.25)
> L <- ggplot(cardataClean, aes(x = Precio.de.Venta)) +
+   geom_histogram(aes(y = ..density..),
+                 colour = 1, fill = "#99FF00") +
+   geom_density(lwd = 1, colour = "#C71F3C",
+               fill = 4, alpha = 0.25)
> A+B+C+D+E+f+G+H+L

```




De estos histogramas de nuestras variables cuantitativas, podemos observar, que ninguna variable sigue una distribución normal, que la variable [Alto.del.auto](#), [Año.de.fabricacion](#), tienen un sesgo negativo a la izquierda. Las variables [Ancho.del.Auto](#), [Capacidad.de.Gasolina](#), [Cilindrada.del.motor](#), [Kilometraje.del.auto](#), [Largo.del.auto](#) y [Precio de Venta](#), presentan un sesgo positivo hacia la derecha.

Diagramas de Barras y de Pastel:


Ahora pasemos a nuestras variables categóricas, también en este apartado se verá reflejado lo trabajado anteriormente en limpieza de datos.

```
> plot_bar(cardataClean)
```



De estos histogramas, se extrae la siguiente información, que se venden muchos autos de tipo Diesel, tambien los mas vendidos son de transmisión manual, tambien aquellos de color blanco, igualmente que un solo dueño que haya poseido el atuto, de igual modo los autos con traccion FWD y por ultimo la mayor parte de las ventas las hacen indivuos.


```
> porcentajes <- count(cardataClean$Fabricante)
> ggplot(cardataClean, aes(x = "", fill = factor(Fabricante))) +
+   geom_bar(width = 1, stat = "count") +
+   coord_polar(theta = "y") +
+   labs(title = "Distribución de Fabricantes")
```



```

> porcentajes <- count(cardataClean$Modelo)
> ggplot(porcentajes,aes(x="",y=freq, fill=x))+
+   geom_bar(stat = "identity",
+           color="white")+
+   geom_text(aes(label=freq),
+           position=position_stack(vjust=0.5),color="white",size=6)+
+   coord_polar(theta = "y")+
+   labs(title = "Distribución de los Modelos")+
+   scale_fill_discrete(name = "Modelo")

```




En estas gráficas de pastel se ve reflejado el trabajo de la limpieza de datos previa, observando de mejor manera que hay más autos de fabricantes asiáticos, así como modelos de autos pertenecientes al Segmento C.

Boxplots:

Ahora retomaremos las variables cuantitativas, esto para graficarlas en un boxplot, de esta manera sera mas facil ver si alguna de estas variables tienen valores atípicos y si es que son muchos.


```
> A <- ggplot(cardataClean, aes(y = cardataClean$Alto.del.auto)) +
+   geom_boxplot(fill = "#8E6189", color = "black") +
+   labs(title = "Alto del Auto", y = "Alto del auto")
> B <- ggplot(cardataClean, aes(y = cardataClean$Ancho.del.auto)) +
+   geom_boxplot(fill = "#DA9556", color = "black") +
+   labs(title = "Ancho del Auto", y = "Ancho del auto")
> C <- ggplot(cardataClean, aes(y = cardataClean$Año.de.Fabricacion)) +
+   geom_boxplot(fill = "#BEC45C", color = "black") +
+   labs(title = "Año de Fabricacion", y = "Año de fabricacion")
> D <- ggplot(cardataClean, aes(y = cardataClean$Capacidad.de.Gasolina)) +
+   geom_boxplot(fill = "#CC1619", color = "black") +
+   labs(title = "Capacidad de Gasolinas", y = "Capacidad de Gasolinas")
> E <- ggplot(cardataClean, aes(y = cardataClean$`Cilindrada.del.Motor(cc)`))
+
+   geom_boxplot(fill = "#B44922", color = "black") +
+   labs(title = "Cilindrada.del.Motor(cc)", y = "Cilindrada.del.Motor(cc)")
> f <- ggplot(cardataClean, aes(y = cardataClean$Kilometraje.del.auto)) +
+   geom_boxplot(fill = "#C68FB5", color = "black") +
+   labs(title = "Kilometraje del auto", y = "Kilometraje del auto")
> G <- ggplot(cardataClean, aes(y = cardataClean$Largo.del.auto)) +
+   geom_boxplot(fill = "#E0CB48", color = "black") +
+   labs(title = "Largo del Auto", y = "Largo del Auto")
> H <- ggplot(cardataClean, aes(y = cardataClean$Numero.de.asientos)) +
+   geom_boxplot(fill = "#F1D5D0", color = "black") +
+   labs(title = "Numero de asientos", y = "Numero de Asientos")
> L <- ggplot(cardataClean, aes(y = cardataClean$Precio.de.Venta)) +
+   geom_boxplot(fill = "#99FF00", color = "black") +
+   labs(title = "Precio de Venta", y = "Precio de Venta")
> A+B+C+D+E+f+G+H+L
```




En este apartado confirmamos los sesgos vistos en los histogramas, pero también como se mencionó con anterioridad, vemos que la única variable sin valores atípicos, es la variable Largo del Auto, en lo que respecta a las demás variables muestran varios valores atípicos, los cuales se deben tratar según el problema y la solución que se vaya abordar más adelante.

Matriz de correlación y gráficos de dispersión:

```
> corrgram(cardataClean, order = TRUE,  
+         main = "Correlogram of Marketing Data, Ordered",  
+         lower.panel = panel.shade, upper.panel = panel.pie,  
+         diag.panel = panel.minmax, text.panel = panel.txt)
```



```
>pairs(cardataClean[c('Alto.del.auto','Ancho.del.auto','Año.de.Fabricacion','Capacidad.de.Gasolina','Cilindrada.del.Motor(cc)','Kilometraje.del.auto','Largo.del.auto','Numero.de.asientos','Precio.de.Venta')])
```



De los gráficos creados obtenemos, que las variables Ancho.del.auto tiene una fuerte correlación positiva con las variables Largo.del.auto, Cilindrada.del.Motor(cc) y [Capacidad.de.Gasolina](#). La variable Largo.del.auto tiene una correlación fuerte positiva con las variables Cilindrada.del.Motor(cc) y [Capacidad.de.Gasolina](#). La variable [Precio.de.Venta](#), tiene una correlación fuerte positiva con las siguientes variables, Ancho.del.Auto, Largo.del.auto, Cilindrada.del.Motor(cc) y [Capacidad.de.Gasolina](#). La Variable [Cilindrada.de.Motor](#), contiene una correlación fuerte positiva únicamente con la variable [Capacidad.de.Gasolina](#). La variable Alto.del.auto, tienen una correlación fuerte positiva con

la variable [Número.de.Asientos](#). Por último vemos una correlación fuerte negativa con las variables [Año.de.Fabricacion](#) y [Kilometraje.de.auto](#).

Planteamiento del Problema.


Dado el trabajo realizado anteriormente, se dispone el siguiente problema, conociendo las variables, realizar un modelo de minería de datos capaz de predecir el precio de venta de un auto según sus características.

Propuesta de Solución.

Dado las correlaciones fuertes positivas existentes, el tipo de variables, y el resultado que se busca, se selecciona regresión lineal múltiple. Para poder llevar a cabo esta solución, se necesitarán revisar algunos detalles de las variables del dataset, así mismo los supuestos de la regresión lineal una vez creado el modelo, para lo cual primero veremos la distribución de la variable objetivo.

Distribución de la variable objetivo.

```
> ggplot(cardataClean, aes(x = Precio.de.Venta)) +  
+   geom_histogram(aes(y = ..density..),  
+                   colour = 1, fill = "#99FF00") +  
+   geom_density(lwd = 1, colour = "#C71F3C",  
+               fill = 4, alpha = 0.25)
```




Se observa que la variable objetivo no sigue una distribución normal y tiene un sesgo positivo a la derecha, si bien esto no impide que se obtengan buenos resultados, si es importante contemplarlo para el modelo.

Tratamiento de valores atípicos.

Como se vio y se menciona en el apartado de análisis exploratorio de datos, hay diversas variables que contienen muchos valores atípico, y cómo se elige un modelo de regresión para dar solución al problema planteado, estos tipos de modelos son sensibles a los valores atípicos, por lo cual es importante tratar estos valores, para ello haremos lo siguiente, crearemos una función que dado los valores que están debajo del primer cuartil los reemplaza por la media, a los valores que estén por encima del segundo cuartil los reemplazará con la mediana.

```
> impute_outliers <- function(x, removeNA = TRUE){
+   quantiles <- quantile(x, c(0.05, 0.95), na.rm = removeNA)
+   x[x<quantiles[1]] <- mean(x, na.rm = removeNA)
+   x[x>quantiles[2]] <- median(x, na.rm = removeNA)
+   x
+ }

> cardataClean$Alto.del.auto <- impute_outliers(cardataClean$Alto.del.auto)
> cardataClean$Ancho.del.auto <- impute_outliers(cardataClean$Ancho.del.auto)
> cardataClean$Año.de.Fabricacion <-
impute_outliers(cardataClean$Año.de.Fabricacion)
> cardataClean$Capacidad.de.Gasolina <-
impute_outliers(cardataClean$Capacidad.de.Gasolina)
> cardataClean$`Cilindrada.del.Motor(cc)` <-
impute_outliers(cardataClean$`Cilindrada.del.Motor(cc)`)
> cardataClean$Kilometraje.del.auto <-
impute_outliers(cardataClean$Kilometraje.del.auto)
> cardataClean$Largo.del.auto <- impute_outliers(cardataClean$Largo.del.auto)
> cardataClean$Numero.de.asientos <-
impute_outliers(cardataClean$Numero.de.asientos)
> cardataClean$Precio.de.Venta <-
impute_outliers(cardataClean$Precio.de.Venta)
```



Con este trabajo de imputación realizado sobre las variables, se puede observar en el gráfico que hemos reemplazado esos valores atípicos de una forma correcta, logrando así que nuestro modelo no tenga problemas con estos valores.

Entrenamiento del modelo.

Primero particionamos los datos en entrenamientos y validación con la librería `carpet` de la siguiente forma (70% y 30%).

```
> index <- createDataPartition(cardataClean$Precio.de.Venta, p = .70, list = FALSE)
> train <- cardataClean[index, ]
> test <- cardataClean[-index, ]
```

Con los datos y la función "lm()", proporcionaremos la variable objetivo y las demás variables predictivas para crear el modelo lineal múltiple, también imprimimos las estadísticas del modelo.

```
> lmCar <- lm(Precio.de.Venta ~ . , data = train)
> summary(lmCar)
```

Call:

```
lm(formula = Precio.de.Venta ~ ., data = train)
```

Residuals:

Min	1Q	Median	3Q	Max
-3114987	-406080	-70521	250779	3983006

Coefficients:

	Estimate	Std. Error	t value
(Intercept)	-154865640.084	20191529.285	-7.670
FabricanteAmericanos	615219.355	134148.957	4.586
FabricanteAsiatico	203032.686	92997.604	2.183
FabricanteEuropeos	806600.231	107485.814	7.504
ModeloSegmento B	105110.784	128434.957	0.818
ModeloSegmento C	519716.077	240358.972	2.162
ModeloSegmento D	876643.690	318338.649	2.754
ModeloSegmento E	1251971.638	374322.331	3.345
ModeloSegmento F	820387.825	470706.310	1.743
Año.de.Fabricacion	78071.398	10050.121	7.768
Kilometraje.del.auto	-2.105	1.124	-1.873
Tipo.de.TransmisionManual	-419611.755	61900.622	-6.779
Color.del.autoBlack	399720.416	351517.035	1.137
Color.del.autoBlue	516939.578	350252.638	1.476
Color.del.autoBronze	-86940.903	394993.672	-0.220
Color.del.autoBrown	396301.054	359598.113	1.102
Color.del.autoGold	249691.034	391926.077	0.637
Color.del.autoGreen	390917.516	409320.317	0.955
Color.del.autoGrey	263259.211	349958.443	0.752
Color.del.autoMaroon	377210.580	382381.943	0.986
Color.del.autoOrange	404245.212	426034.935	0.949
Color.del.autoOthers	9583.284	420045.165	0.023
Color.del.autoPink	1469048.771	903171.523	1.627
Color.del.autoPurple	457714.456	505839.798	0.905
Color.del.autoRed	297937.634	352947.017	0.844
Color.del.autoSilver	206777.190	347884.208	0.594
Color.del.autoWhite	332290.368	344415.163	0.965
Color.del.autoYellow	519227.050	467888.605	1.110
Cantidad.de.dueñosFirst	-1195327.747	835986.683	-1.430
Cantidad.de.dueñosFourth	-568516.748	1026041.444	-0.554
Cantidad.de.dueñosSecond	-1212057.000	837106.439	-1.448
Cantidad.de.dueñosThird	-1210630.017	849398.244	-1.425
Cantidad.de.dueñosUnRegistered Car	-142886.355	871167.767	-0.164
Tipo.de.VendedorCorporate	256387.822	443163.808	0.579

Tipo.de.VendedorIndividual	5329.297	422190.200	0.013
`Cilindrada.del.Motor(cc)`	376.918	82.526	4.567
Tipo.de.traccionFWD	-269608.187	94510.728	-2.853
Tipo.de.traccionRWD	113675.279	90077.231	1.262
Largo.del.auto	-591.893	285.164	-2.076
Ancho.del.auto	475.084	404.530	1.174
Alto.delauto	484.778	292.088	1.660
Numero.de.asientos	-7376.095	45629.404	-0.162
Capacidad.de.Gasolina	-7842.884	3133.081	-2.503
	Pr(> t)		
(Intercept)	0.00000000000000321	***	
FabricanteAmericanos	0.0000049198153318	***	
FabricanteAsiatico	0.029187	*	
FabricanteEuropeos	0.00000000000001094	***	
ModeloSegmento B	0.413270		
ModeloSegmento C	0.030768	*	
ModeloSegmento D	0.005967	**	
ModeloSegmento E	0.000846	***	
ModeloSegmento F	0.081573	.	
Año.de.Fabricacion	0.00000000000000153	***	
Kilometraje.del.auto	0.061214	.	
Tipo.de.TransmisionManual	0.000000000000178139	***	
Color.del.autoBlack	0.255679		
Color.del.autoBlue	0.140194		
Color.del.autoBronze	0.825820		
Color.del.autoBrown	0.270622		
Color.del.autoGold	0.524172		
Color.del.autoGreen	0.339722		
Color.del.autoGrey	0.452022		
Color.del.autoMaroon	0.324070		
Color.del.autoOrange	0.342858		
Color.del.autoOthers	0.981801		
Color.del.autoPink	0.104059		
Color.del.autoPurple	0.365695		
Color.del.autoRed	0.398734		
Color.del.autoSilver	0.552351		
Color.del.autoWhite	0.334814		
Color.del.autoYellow	0.267309		
Cantidad.de.dueñosFirst	0.152986		
Cantidad.de.dueñosFourth	0.579608		
Cantidad.de.dueñosSecond	0.147866		
Cantidad.de.dueñosThird	0.154299		
Cantidad.de.dueñosUnRegistered Car	0.869741		
Tipo.de.VendedorCorporate	0.562993		
Tipo.de.VendedorIndividual	0.989930		
`Cilindrada.del.Motor(cc)`	0.0000053758306157	***	
Tipo.de.traccionFWD	0.004399	**	
Tipo.de.traccionRWD	0.207168		
Largo.del.auto	0.038111	*	
Ancho.del.auto	0.240431		
Alto.delauto	0.097199	.	
Numero.de.asientos	0.871603		
Capacidad.de.Gasolina	0.012419	*	

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 830200 on 1399 degrees of freedom
Multiple R-squared:  0.5093,    Adjusted R-squared:  0.4946 
F-statistic: 34.57 on 42 and 1399 DF,  p-value: < 0.000000000000000022
```

Con estas estadísticas podemos concluir lo siguiente, existen muchas variables que no aportan al modelo como la variable Color, Largo.del.auto, [Capacidad.de.Gasolina](#), etc. También nuestra R-square es de 0.509, o 50.9% de exactitud con nuestro modelo, con lo cual se concluye que es un mal modelo.


Comprobación de supuestos de regresión lineal.


Esta parte es fundamental ya que el algoritmo hace suposiciones, por lo tanto si el modelo no cumple con dichos supuestos entonces no podemos hacer uso del modelo.

Los errores deben seguir una distribución normal.

Para esto haremos uso de la función “hist()” y “plot()”, para trazar los residuos en un gráfico y poder comprobar si cumple con este supuesto.

```
> hist(lmCar$residuals)
> plot(lmCar)
```






Para este supuesto vemos que los residuos del modelo si siguen una distribución normal, por lo tanto este supuesto se cumple.

No debe haber heterocedasticidad.

Para que se cumpla esto la varianza de los errores debe ser constante, no ver ningún patrón entre residuos y valores ajustados, por último la línea media debe ser cercana a cero. Para esto usaremos la función "Plot()".

```
> plot(lmCar)
```



Para este supuesto el modelo no lo cumple, debido a que si existe una correlación (patrón) entre los residuos y los valores ajustados.

No debe haber multicolinealidad.

Para saber si existe multicolinealidad haremos uso del cálculo del factor de inflación de la varianza (VIF), si el valor es igual o aproximado a uno quiere decir que no existe multicolinealidad en la variables, pero si es el valor está entre $1 < VIF < 5$ entonces existe una moderada correlación, si el VIF es mayor a 5 entonces hay una alta correlación, para hacer esto cálculos nos apoyamos en la librería “car” y la función “vif()” de esta misma.

```
> vif(lmCar)
```

	GVIF	Df	$GVIF^{(1/(2*Df))}$
Fabricante	3.383673	3	1.225269
Modelo	60.151239	5	1.506345
Año.de.Fabricacion	1.473736	1	1.213975
Kilometraje.del.auto	1.398697	1	1.182665
Tipo.de.Transmision	1.981958	1	1.407820
Color.del.auto	1.640464	16	1.015588
Cantidad.de.dueños	1.317262	5	1.027939
Tipo.de.Vendedor	1.077802	2	1.018908
`Cilindrada.del.Motor(cc)`	3.154897	1	1.776203
Tipo.de.traccion	3.069019	2	1.323579
Largo.del.auto	33.067146	1	5.750404
Ancho.del.auto	3.009065	1	1.734666
Alto.delauto	1.931490	1	1.389780
Numero.de.asientos	1.912719	1	1.383011
Capacidad.de.Gasolina	2.934647	1	1.713081

Con estos resultados se demuestra que el modelo no cumple con esta supuesto, ya que la variable Largo.del.auto, tiene una correlación fuerte.

No debe haber correlación serial automática.

En este último supuesto buscaremos verificar que los términos de error no deben estar correlacionados entre sí, para ello se hará uso de la librería “lmtest” y la función “dwtest()”, la cual devuelve un valor entre 0 y 4, si el valor devuelto es dos entonces decimos que no existe correlación serial automática, pero si el valor es mayor a dos, entonces existe una correlación negativa, si es menor que dos tiene una correlación positiva.

```
> dwtest(lmCar)
```

Durbin-Watson test

```
data: lmCar
DW = 1.9424, p-value = 0.1363
alternative hypothesis: true autocorrelation is greater than 0
```

El valor devuelto es menor que 2, por lo cual nos indica que no se cumple el no tener correlación serial automática.

Después de la evaluación de los supuestos, nuestro modelo solo cumple 1 de los 4 supuestos, por lo cual hay mejoras importantes que se pueden llevar a cabo para que el modelo cumpla con todos estos, al igual que cambios relevantes para mejorar el modelo, estos cambios y mejoras se abordan más adelante.

Medición del Modelo.

Para este tema, haremos uso de nuestra partición de datos "test" y del modelo creado, si bien sabemos con anticipación que no es buen modelo aun así es importante ver cómo se comporta el modelo con nuevos datos haremos uso de la función "predict()".

```
> test$PreditedPrice <- predict(lmCar, test)
> head(test[, c("Precio.de.Venta", "PreditedPrice")])
```

	Precio.de.Venta	PreditedPrice
2	450000	255344.7
3	1702992	222932.4
4	799000	728956.7
5	1950000	2115448.1
8	2650000	2232616.0
12	459999	1046527.3

Una vez teniendo los datos predichos por el modelo, podemos obtener la R-square del conjunto de prueba, para así saber la precisión del modelo sobre el conjunto de prueba con la siguiente fórmula ejecutada en R.

```
> actual <- test$Precio.de.Venta
> preds <- test$PreditedPrice
> rss <- sum((preds - actual) ^ 2)
```

```
> tss <- sum((actual - mean(actual)) ^ 2)
> rsq <- 1 - rss/tss
> rsq
```

```
[1] 0.4899457
```

Vemos que con esto realizado en nuestro conjunto de prueba nuestro modelo obtuvo 50.9% de precisión y en nuestra partición de validación tuvo un 48.9% esto es consistente, respecto al modelo, pero en si es un mal modelo.

Posibles mejoras al modelo.

Las posibles mejora para este modelo, serían a partir de lo obtenido con el modelo anterior más específicamente en la función estadística (summary) del modelo, la cual nos arroja aquellas variable que no son relevantes para el modelo, también al comprobar los supuestos del modelo vemos que tiene algunos conflicto con la multicolinealidad en una variable, lo propuesto para esta parte sería eliminar esa variable del modelo para que ese supuesto se cumpla.

Conclusiones.

Con este trabajo terminado, se ve con mayor claridad el cómo hacer un modelo de minería de datos, no solo se basa en el algoritmo, sino también el trabajo previo realizado a los datos, tanto la extracción de los mimos, como la limpieza de los datos, ya que de no hacer una buen extracción y limpieza el modelo no funcionará correctamente. También la importancia que tiene la exploración de los datos, ya que esto es fundamental para escoger el algoritmo adecuado para dar solución a la problemática de la forma correcta, ya que a través de la exploración es como conocemos el comportamiento de las variables de nuestros datos. Con todo este trabajo previo es como se puede realizar un buen modelo adecuado a las circunstancias, así mismo la importancia del trabajo posterior al modelo el cual es evaluarlo y buscar posibles mejoras.